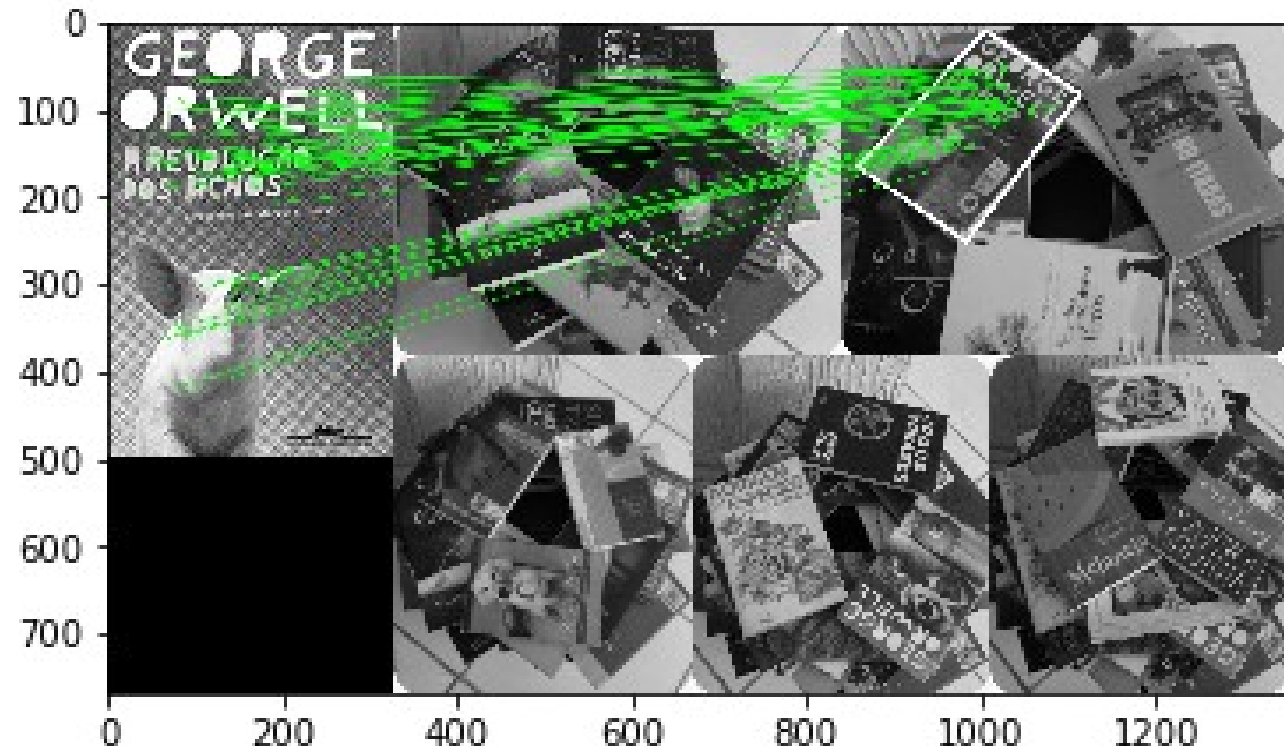


Tarefa de SIFT



Detectando os keyPoints

- Depois da leitura da imagem “livro1.png” e sua conversão em escala de cinza:

```
# inicializa o SIFT e detecta os keypoints
```

```
sift1 = cv2.xfeatures2d.SIFT_create()
```

```
kp1 = sift.detect(gray1, None)
```

```
# os keypoints são pontos salientes, mas não são características. O kp1  
basicamente fornece as localizações
```

Desenhando os keyPoints

- A função abaixo desenha bolinhas nas posições nas quais os keypoints foram detectados

```
cv2.drawKeypoints(gray1, kp1, img1)  
cv2.imwrite('sift_keypoints1.jpg', img1)
```



Desenhando os keyPoints

- Pode-se usar o parâmetro que fará com que o desenho das bolinhas já indique a orientação e o tamanho do keyPoint

```
cv2.drawKeypoints(gray1, kp1, img1)  
cv2.imwrite('sift_keypoints1.jpg', img1)
```



Calculando as Features

- Agora, pode-se usar função que transforma cada keyPoint em uma feature (vetor de características) de tamanho 128

```
kp1, des1 = sift.detectAndCompute(gray1, None)
```

Comparando duas imagens

- Faça o mesmo procedimento que foi feito anteriormente para “livros1.png” (repare no plural)



Feature Matching (Força Bruta)

- Brute-Force matcher (BFMatcher): calcula a distância de uma feature de uma imagem com todas as outras features da outra imagem. Retornam-se os dados das duas features de menor distância.
- `bf = cv2.BFMatcher()`
 - Parâmetro 1: default é `cv2.NORM_L2`, que é bom para SIFT e SURF (`cv2.NORM_L1` também é bom). Para vetores binários como os descritores de ORB, BRIEF e BRISK é melhor o `cv2.NORM_HAMMING`.
 - Parâmetro 2: variável booleana, `crossCheck` é falso por padrão. Se for verdade, o Matcher retorna apenas as correspondências com valor (i, j) , de modo que o i -ésimo descritor no conjunto A tenha j -ésimo descritor no conjunto B como a melhor combinação e vice-versa. Ou seja, as duas características em ambos os conjuntos devem corresponder uns aos outros.

Feature Matching (Força Bruta)

- Depois, pode-se usar a função `FMatcher.match ()` ou a função `BFMatcher.knnMatch ()`.
 - O primeiro retorna a melhor combinação (menor distância).
 - O segundo método retorna k melhores combinações, onde k é especificado pelo usuário.

Desenhando os Matches

- `cv2.drawMatches()`
- Desenhar as combinações.
- Coloca lado a lado duas imagens horizontalmente e desenha linhas da primeira imagem para a segunda imagem, mostrando melhores correspondências.
- Há também `cv2.drawMatchesKnn` que desenha todas as melhores combinações k . Se $k = 2$, desenhará duas linhas de correspondência para cada ponto chave.


Desenhando os Matches

```
# BFMatcher with default params
bf = cv2.BFMatcher()
#bf = cv2.BFMatcher(cv2.NORM_L1,crossCheck=False)
matches = bf.knnMatch(des1,des2, k=2)

# Apply ratio test
good = []
for m,n in matches:
    if m.distance < 0.75*n.distance:
        good.append([m])

# cv2.drawMatchesKnn expects list of lists as matches.
img3 = cv2.drawMatchesKnn(img1,kp1,img2,kp2,good,None, flags=2)

plt.imshow(img3),plt.show()
```



Desenhando os Matches


```
# FLANN parameters
FLANN_INDEX_KDTREE = 0
index_params = dict(algorithm = FLANN_INDEX_KDTREE, trees = 5)
search_params = dict(checks=50) # or pass empty dictionary
flann = cv2.FlannBasedMatcher(index_params,search_params)
matches = flann.knnMatch(des1,des2,k=2)
```

```
# Need to draw only good matches, so create a mask
matchesMask = [[0,0] for i in range(len(matches))]
```

```
# ratio test as per Lowe's paper
for i,(m,n) in enumerate(matches):
    if m.distance < 0.7*n.distance:
        matchesMask[i]=[1,0]
```

```
draw_params = dict(matchColor = (0,255,0), singlePointColor = (255,0,0), matchesMask = matchesMask, flags = 0)
```

```
img3 = cv2.drawMatchesKnn(img1,kp1,img2,kp2,matches,None,**draw_params)
plt.imshow(img3),plt.show()
```



Desenhando os Matches

```
# create BFMatcher object
```

```
bf = cv2.BFMatcher(cv2.NORM_L1, crossCheck=True)
```

```
# Match descriptors.
```

```
matches = bf.match(des1,des2)
```

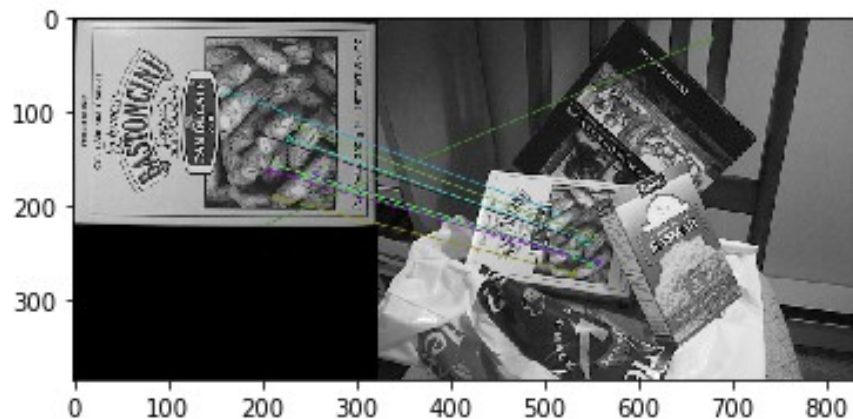
```
# Sort them in the order of their distance.
```

```
matches = sorted(matches, key = lambda x:x.distance)
```

```
# Draw first 10 matches.
```

```
img3 = cv2.drawMatches(img1,kp1,img2,kp2,matches[:10], None, flags=2)
```


```
plt.imshow(img3),plt.show()
```





Desenhando os Matches

Teste a versão que está em:

https://docs.opencv.org/3.0-beta/doc/py_tutorials/py_feature2d/py_feature_homography/py_feature_homography.html



Exemplo de Aplicação



Tarefa

- O aluno deve fazer uma proposta de uma aplicação “real” que use matching de descritores.
- Fazer testes com os descritores SIFT, SURF, ORB, BRIEF e BRISK
- Deve criar uma pequena base de dados com pelo menos 20 imagens dessa aplicação. Esta base de dados deve estar variada de tal forma a se ter casos de sucesso e casos de fracasso.